

Kalabalıkta İnsan-Merkezli Navigasyon için V38: SNCP-PPO Üzerinde Eğitimsiz Eylem Kalkanı

Orkun Koray Güngör
Mekatronik Mühendisliği Bölümü
Bursa Teknik Üniversitesi
Bursa, Türkiye
orkun9312@gmail.com

Özet—Kalabalıkta sosyal navigasyon, öğrenilmiş rota seçimi ile yürütme zamanı güvenliğini aynı anda gerektirir. Bu çalışma, SNCP-PPO tabanlı kalabalık navigasyon projesinin nihai V38 sistemini raporlar. Önceki sürümler, ön-MLP gömmesi, yoğunluk müfredatı, mean+max havuzlama ve Beta eylem dağılımı ile güçlü bir v34 tabanı üretmiş; ancak yüksek yoğunlukta kalan hata kipinin büyük ölçüde çarpışma olduğunu göstermiştir. V38 bu nedenle yeni bir PPO eğitimi yapmaz. Kilitli v34 Beta checkpoint'inin deterministik eylemi alınır; kısa-horizon sabit-hız öngörüsüyle çarpışma riski kontrol edilir; yalnızca riskli durumda daha düşük riskli bir alternatif eylem yürütülür. Bu eğitimsiz action-shield katmanı, aynı checkpoint, aynı değerlendirme tohumları ve aynı bölümler üzerinde ham v34 ile karşılaştırıldığında N=20 başarıyı %86.0'dan %98.8'e çıkarır ve çarpışmayı %13.2'den %0.4'e indirir. Dürüst 5-değerlendirme-tohumu havuzunda (250 bölüm/yoğunluk) final V38 başarıları N=5/10/15/20 için %99.6/%99.6/%99.6/%98.8, çarpışmalar ise %0.0/%0.0/%0.4/%0.4'tür. Böylece V38, yeni checkpoint eğitmeden, öğrenilmiş sosyal rotayı koruyup çarpışma sınırındaki eylemi düzelten pratik bir final sistem adayını sunar.

Index Terms—sosyal navigasyon, kalabalıkta robot hareketi, PPO, SNCP, action shield, çarpışma-risk filtresi

I. GİRİŞ

Kalabalıkta mobil robot navigasyonu, yalnızca geometrik olarak kısa bir yol bulmak değildir. Robot hedefe ulaşırken yayaların hareketini hesaba katmalı, çarpışmadan kaçınmalı ve yoğunluk arttıkça güvenli geçiş fırsatlarını değerlendirilidir. Referans aldığımız SNCP-PPO yaklaşımı, bu problemi robot ve yayalar arasındaki etkileşimi uzay-zamansal bir grafa dönüştürerek çözer; Liquid Time-Constant ve Neural Circuit Policy kodlayıcılarıyla etkileşimleri işler ve son eylemi PPO ile öğrenir [1], [2], [3], [4]. Yaya hareketi için CrowdNav çizgisindeki görünmez-robot varsayımı ve ORCA kalabalık dinamiği kullanılır [5], [6].

Projedeki erken amaç, referans makaledeki yüksek başarı oranına saf öğrenilmiş politika ile yaklaşmaktır. Bu süreçte birçok mimari ve eğitim kararı test edildi. Sonuçta v34 Beta politikası güçlü ve dengeli bir taban oldu: sınırlı eylem uzayında Beta dağılımı, kırılmış Gauss politikasına göre daha uygun bir yürütme davranışı sağladı [7]. Buna rağmen yüksek yoğunlukta kalan başarısızlıkların çoğu zaman aşımı değil,


çarpışmaydı. Bu gözlem, yeni bir büyük eğitim koşusu yerine yürütme zamanı çarpışma-risk filtresini daha savunulabilir son adım yaptı.

Bu makalenin odağı bu son adımdır. V38, v34 checkpoint'ini değiştirmez; öğrenilmiş rotayı korur ve sadece kısa-horizon çarpışma riski olan eylemleri değiştirir. Katkılarımız:

- Kilitli v34 Beta politikasının üzerine eğitimsiz, kısa-horizon action-shield katmanı ekliyoruz.
- Kalkan etkisini aynı checkpoint, aynı değerlendirme tohumları ve aynı bölüm bankası üzerinde ham v34'e karşı izole ediyoruz.
- Dürüst 5-değerlendirme-tohumu havuzunda final V38 sisteminin N=20 challenging başarısını %98.8'e çıkardığını ve çarpışmayı %0.4'e indirdiğini gösteriyoruz.
- Raporu eski ablation figürlerine dayandırmadan, V38 final sistemine özel yeni tablolar ve görsellerle sunuyoruz.

Bu yaklaşım, öğrenen ajanın eylemini izleyip yalnızca güvenlik ihlali öngörüldüğünde düzelten “shielded reinforcement learning” fikrine yakındır [8]. Bununla birlikte V38, zamansal mantıkla sentezlenmiş biçimsel bir kalkan veya ileri-değişmezlik garantisi veren bir control-barrier-function denetleyicisi değildir [9]. Buradaki amaç, kilitli v34 politikasının iyi sosyal rota kararını korurken, kısa ufukta açıkça riskli görünen sürekli eylemi pratik bir aday eylem aramasıyla değiştirmektir.

II. YÖNTEM



Şekil 1. V38 yürütme hattı. Kilitli v34 Beta politikası sosyal rota üretir; V38 kalkanı yalnızca kısa-horizon çarpışma riski görüldüğünde eylemi değiştirir. Checkpoint ağırlıkları değişmez.

A. Kilitli v34 Beta politikası

Taban politika, SNCP-PPO mimarisinin v34 Beta checkpoint'idir. Bu checkpoint, robotun kalabalıkta doğrudan beeline yerine kavisli ve sosyal açıdan makul rotalar üretmesini sağlar. V34'ün bu çalışmadaki rolü sabittir: ağırlıkları değiştirilmez, yeniden eğitim yapılmaz ve V38'in öğrenilmiş bileşeni olarak korunur. Böylece V38'in etkisi, politika mimarisindeki yeni bir öğrenmeden değil, yalnız yürütme zamanı çarpışma-risk filtresinden gelir.

B. V38 action shield

V38, deterministik politika eylemini bir çarpışma-risk filtresinden geçirir. İş akışı Şekil 1'da özetlenmiştir. Politika önce (v, ω) eylemini önerir. Kalkan, robot ve yayalar için 6 adımlık sabit-hız öngörüsü yapar. Öngörü ufkı içinde robot-yaya mesafesi çarpışma sınırını ihlal etmiyorsa eylem aynen yürütülür. Risk varsa, sınırlı bir aday eylem kümesi taranır ve çarpışma riskini azaltırken hedefe ilerlemeyi mümkün olduğunca koruyan alternatif seçilir.

Kalkanın kritik özelliği seçici olmasıdır: her adımda politika çıktısını yeniden planlamaz, yalnızca kısa ufukta risk görüldüğünde devreye girer. Bir politika eylemi $a_\pi = (v_\pi, \omega_\pi)$ için önce robotun mevcut pozu, yayaların mevcut konumları ve yayaların anlık hızları alınır. Robotun a_π ile, yayaların ise sabit hızla ilerlediği varsayılarak $H = 6$ adımlık bir mikro-rollout yapılır. Bu rollout'taki en küçük robot-yaya mesafesi $d_{\min}$ ise kalkan açıklığı

$$\rho(a_\pi) = d_{\min} - d_{\text{coll}} \quad (1)$$

olarak hesaplanır. Burada d_{coll} ortamın robot-yaya çarpışma eşiğidir. Eğer $\rho(a_\pi) \geq m$ ise, yani öngörülen açıklık risk marjı m 'den büyükse, a_π değiştirilmez.

Riskli durumda kalkan küçük bir eylem kafesi dener. Doğrusal hız kafesi durma, çeyrek/yarım/üç-çeyrek/tam hız ve politika hızının yarım/üç-çeyrek/tam değerlerini içerir. Açısal hız kafesi ise maksimum sağ/sol dönüş, yarım maksimum sağ/sol dönüş, düz gitme ve politikanın önerdiği dönüşten oluşur. Her aday aynı mikro-rollout ile değerlendirilir ve aşağıdaki maliyetin en küçüğünü veren eylem seçilir:

$$J(a) = \lambda_c \mathbf{1}[\rho(a) < 0] + \lambda_s \max(0, m - \rho(a))^2 - \lambda_p \Delta d_g(a) + \lambda_d \|a - a_\pi\|_{\text{norm}} + \lambda_v \left(1 - \frac{v}{v_{\max}}\right). \quad (2)$$

Bu maliyet çarpışmayı baskın şekilde cezalandırır, öngörülen açıklık azaldığında ek ceza verir, hedefe ilerlemeyi ödüllendirir ve v34 politikasının önerdiği eylemden gereksiz sapmayı sınırlar. Bu nedenle V38, tam bir yörünge planlayıcı veya yeni bir öğrenilmiş politika değildir; v34'ün sosyal rota kararını koruyan, yalnızca çarpışma sınırındaki eylemleri düzelten yürütme zamanı risk filtresidir.

Bu çalışmada kullanılan sayısal değerler $H = 6$, $m = 0.0$, $\lambda_c = 1000.0$, $\lambda_s = 20.0$, $\lambda_p = 1.0$, $\lambda_d = 0.05$ ve $\lambda_v = 0.02$ 'dir. Katsayılar ayrı bir öğrenme veya geniş ızgara aramasıyla ayarlanmamıştır; çarpışmayı baskın öncelik yapan,

sonra açıklık, hedef ilerlemesi, politika eyleminden sapma ve gereksiz yavaşlama arasında sezgisel bir sıralama kuran sabit mühendislik parametreleri olarak seçilmiştir.

Bu tasarım bilinçli olarak küçüktür. Eğitim gerektirmez, v34'ün başarılı sosyal rota davranışını bozmadı ve yalnızca teşhis edilen hata kipine, yani çarpışma sınırındaki yanlış eylemlere müdahale eder.

III. DENEY PROTOKOLÜ

Ana değerlendirme `paper_challenging` senaryosunda yapılır: 15×15 m arena, ORCA yayalar, görünmez robot ve 1.0 m/s robot/yaya hız rejimi. Yoğunluklar $N = \{5, 10, 15, 20\}$ olarak seçilir.

Tablo I
V38 FINAL DENEY KURULUMU.

Bileşen	Ayar
Senaryo	<code>paper_challenging</code>
Yoğunluklar	5, 10, 15, 20 yaya
Değerlendirme	5 eval tohumu $\times$ 50 bölüm = 250 bölüm/yoğunluk
Taban politika	v34 Beta checkpoint
Karşılaştırma	Ham v34 vs v38 shield
Robot/yaya hızı	1.0 m/s
Kalkan ufkı	6 adım sabit-hız öngörüsü
Kalkan marjı	0.0
İstatistik	Wilson GA; havuzlanmış z + Bonferroni $\alpha = 0.0125$

Kalkan etkisini izole etmek için ham v34 ve V38 aynı checkpoint, aynı değerlendirme tohumları ve aynı bölüm bankası üzerinde karşılaştırılır. Bu düzende tek fark, yürütme zamanı action shield katmanıdır. Başarı, çarpışma ve zaman aşımı bölüm yüzdesi olarak raporlanır; başarılı bölümlerin ortalama adım sayısı, sosyal rotanın korunup korunmadığını yorumlamak için ayrıca verilir. Buradaki beş tohum, yeni PPO eğitim tohumları değil, kilitli tek v34 checkpoint üzerinde kullanılan değerlendirme tohumlarıdır. Ana tablolardaki 250 bölüm/yoğunluk sonuçları `paper_data/v34_multiseed_result.json` ve `paper_data/v38_multiseed_result.json` dosyalarından gelir; `eval_v38` artefaktları ise ek rapor ve yörünge görselleri için korunur.

Kalkan maliyeti ayrıca yerel CPU üzerinde, yalnız `shield_action` çekirdeğini kapsayan 1000 çağrılık bir ön mikro-ölçümle kontrol edildi. Aynı $H = 6$ ayarıyla medyan süre $N=5/10/15/20$ için yaklaşık 0.108/0.108/0.113/0.123 ms, 95. yüzdelerik süre ise 5.6/5.8/5.9/6.6 ms ölçüldü. Bu ön ölçüm, kalkan çekirdeğinin 10 Hz kontrol döngüsündeki 100 ms karar bütçesinin altında kalabileceğini gösterir; ancak politika çıkarımı, algılama, ROS iletişimi ve gerçek robot entegrasyonu bu süreye dahil değildir.

RL sonuçlarının tohum ve bölüm seçimine duyarlı olabildiği bilindiğinden [10], [11], p-değerleri Wilson güven aralıklarıyla birlikte ve destekleyici karar ölçütü olarak yorumlanır. Aynı bölüm bankası kullanıldığı için ideal ek analiz, bölüm-düzeyi

eşleşmiş sonuçlardan McNemar testi veya paired bootstrap güven aralığı üretmek; mevcut artefaktlarda karar, havuzlanmış iki-oranlı z testi ve Bonferroni düzeltmesi ile raporlanmıştır.

IV. SONUÇLAR

A. Kalkan etkisi: ham v34'ten V38'e

Tablo II, Tablo III ve Şekil 2, V38 kalkanının doğrudan etkisini gösterir. Havuzlanmış iki-oranlı z testine göre kalkan N=10, N=15 ve N=20'de başarıyı Bonferroni eşliğinde artırır; çarpışmayı dört yoğunlukta da aynı eşikte azaltır. N=20'de başarı %86.0'dan %98.8'e çıkar, çarpışma %13.2'den %0.4'e iner. Zaman aşımı %0.8 ve altında kaldığı için iyileşme robotu durdurarak değil, çarpışma sınırındaki eylemleri düzelterek gelir.

Tablo II


V38 ACTION SHIELD BAŞARI ETKİSİ. DEĞERLER YÜZDE; KALIN P-DEĞERLERİ HAVUZLANMIŞ z TESTİNDE BONFERRONI EŞİĞİNİ GEÇER ($p < 0.0125$).

N	v34	V38	Δ	p
5	96.8	99.6	+2.8	0.019
10	92.8	99.6	+6.8	$< 10^{-3}$
15	91.2	99.6	+8.4	$< 10^{-3}$
20	86.0	98.8	+12.8	$< 10^{-3}$

Tablo III

V38 ACTION SHIELD ÇARPİŞMA VE ZAMAN AŞIMI ETKİSİ. ÇARPİŞMA İÇİN NEGATİF Δ DAHA İYİDİR; KALIN P-DEĞERLERİ HAVUZLANMIŞ z TESTİNDE BONFERRONI EŞİĞİNİ GEÇER ($p < 0.0125$).

N	v34 ç.	V38 ç.	Δ ç.	p	V38 z.aş.
5	2.8	0.0	-2.8	0.008	0.4
10	7.2	0.0	-7.2	$< 10^{-3}$	0.4
15	8.8	0.4	-8.4	$< 10^{-3}$	0.0
20	13.2	0.4	-12.8	$< 10^{-3}$	0.8



Şekil 2. V38 kalkanının izole etkisi. Sol: ham v34'e göre başarı artışı. Sağ: çarpışma azalması. Etki yüksek yoğunlukta daha belirgindir.

B. Final V38 sistem metrikleri

Final V38 sisteminin ana metrikleri Tablo IV ve Şekil 5'te verilmiştir. Başarı N=5/10/15/20 için %99.6/%99.6/%99.6/%98.8'dir. N=20'de bu değer, bu

çalışmadaki paper_challenging yeniden-uygulamasında referans makaledeki yaklaşık %94 challenging düzeyiyle aynı bandın üst tarafına gelir. Çarpışma oranı tüm yoğunluklarda %0.4 veya altındadır. Başarılı bölüm adımı 47.2'den 60.1'e doğru yoğunlukla artar; bu, robotun kalabalığa göre rotasını hâlâ uzattığını ve kalkanın sistemi düz-çizgi ya da durma davranışına zorlamadığını gösterir.


Tablo IV
FINAL V38 KALKANLI SİSTEM METRİKLERİ. 5 TOHUM $\times$ 50 BÖLÜM = 250 BÖLÜM/YOĞUNLUK.

N	Başarı [%95 GA]	Çarpışma	Z.aşımı	Ort. başarı adımı	Ort. I_{sp}
5	99.6 [97.8, 99.9]	0.0	0.4	47.2	0.0074
10	99.6 [97.8, 99.9]	0.0	0.4	52.1	0.0059
15	99.6 [97.8, 99.9]	0.4	0.0	57.6	0.0047
20	98.8 [96.5, 99.6]	0.4	0.8	60.1	0.0038

C. Bağlam: v30, v34 ve V38

Şekil 3, V38'i önceki iki önemli noktayla karşılaştırır. v30, öğrenilmiş politika hattındaki ana ara şampiyondur; v34, aynı hattın Beta eylem dağılımlı güçlü checkpoint'idir. V38 bu iki checkpoint'ten farklı olarak yeni öğrenilmiş ağırlıklar değil, v34 üzerinde çalışan runtime filtredir. Bu nedenle V38'in yüksek-N kazancı, daha büyük modelden değil, hata kipine doğrudan müdahaleden gelir.

N=20 başarı %86.0'dan %98.8'e çıkar, çarpışma %13.2'den %0.4'e iner. Final değerlendirme havuzunda V38 tüm yoğunluklarda %98.8 ve üzeri başarı verir. Sonuç olarak V38, yeni eğitim gerektirmeyen güçlü ve pratik bir final sistem adaydır.




Şekil 3. Bağlam karşılaştırması. V30 ve v34 saf öğrenilmiş politikalar; V38, v34 üzerine eklenen çarpışma-risk filtresidir. Runtime kalkan bu değerlendirmede yüksek yoğunlukta çarpışma kipini güçlü biçimde azaltır.


D. Yörünge örnekleri

Şekil 4, N=10 ve N=20 için V38 kalkanlı yörüngeleri gösterir. Robot kalabalığın içinden düz bir çizgiyle geçmek yerine, yoğunluk arttıkça daha uzun ve kavisli rotalar üretir. Bu niteliksel sonuç, Tablo IV'deki ortalama başarılı adım sayısıyla uyumludur.

V38 shielded trajectory, N=10




V38 shielded trajectory, N=20



paper_challenging, locked v34 Beta checkpoint + V38 action shield

Şekil 4. V38 kalkanlı yörünge örnekleri. Kalkan, sosyal rotayı korur; yalnızca çarpışma sınırındaki eylemleri değiştirir.



Şekil 5. Final V38 yoğunluk sweep'i. Başarı yüksek kalır, çarpışma ve zaman aşımı düşük kalır. Başarılı yol uzunluğu yoğunlukla arttığı için sosyal rota davranışı korunur.

V. TARTIŞMA

V38 sonucunun doğru okunması gerekir. Bu sistem yeni bir PPO checkpoint'ini değildir. Öğrenilmiş bileşen v34 Beta politikasıdır; V38 bu politikanın yürütme zamanı eylemini çarpışma riski açısından denetler. Bu nedenle sonuç, "daha iyi eğitilmiş saf SNCP" değil, "öğrenilmiş sosyal rota + analitik risk filtresi" olarak değerlendirilmelidir.

Bu ayırım pratik açıdan avantajdır. Yeni bir tam PPO eğitimi saatler sürebilir ve daha önce öğrenilmiş güçlü davranışı bozabilir. V38 ise mevcut checkpoint'ini korur ve yalnızca riskli eylem sınırında müdahale eder. Eşleştirilmiş sonuçlarda düşük yoğunlukta anlamlı gerileme olmaması, yüksek yoğunlukta ise çarpışmanın neredeyse sıfırlanması bu tasarım tercihini destekler.

V38'in sınırlamaları da açıktır. Kalkan kısa-horizon sabit-hız öngörüsüne dayanır; gerçek robotta bu öngörü algılama gürültüsü ve gecikmeden etkilenebilir. ORCA yayaları bir sonraki adımda yön veya hız değiştirebildiği için sabit-hız varsayımı bazen yanlış pozitif uyarı üretebilir ve gereksiz küçük rota düzeltmelerine neden olabilir; daha nadir olarak ani yaya manevrası yanlış negatif risk de oluşturabilir. Kısa ufuk bu etkiyi sınırlar, fakat gerçek zamanlı robot uygulamasında bu varsayım ayrıca test edilmelidir. Ayrıca V38 özellikle challenging rejimdeki çarpışma kipini hedefler; standard senaryoda görülen zaman bütçesi kaynaklı hatalar ayrı seçim veya ince

ayar gerektirebilir. Sonuçlar tek kilitli v34 eğitim checkpoint'ini üzerinde ve beş değerlendirme tohumunda gösterilmiştir; farklı PPO eğitim tohumlarına genelleme ayrıca test edilmemiştir. Aynı bölüm bankası üzerindeki eşleştirme için McNemar veya paired bootstrap gibi bölüm-düzeyi analizler gelecek çalışmada daha uygun bir tamamlayıcı istatistik sağlayabilir. Gelecek iş olarak kalkan davranışı politikaya distile edilebilir veya PPO eğitimi sırasında risk filtresi ile birlikte öğrenme denenebilir.

VI. SONUÇ

Bu makale, SNCP-PPO projesinin mevcut nihai durumunu V38 final sistemi olarak yeniden çerçeveler. Kilitli v34 Beta politikası sosyal rota üreticisi olarak korunur; V38 action shield ise kısa-horizon çarpışma riskini yürütme zamanında azaltır. Bu sonuç, öğrenilmiş sosyal rota üretimi ile analitik risk filtresinin birlikte kullanılmasının, ek PPO eğitimi gerektirmeden pratik bir final sistem adayı verebildiğini gösterir.

KAYNAKLAR

- [1] T. Ao, H. Li, Y. Tian *et al.*, "Human-centric motion planning in crowded spaces: A structured neural circuit approach with social interaction-awareness," *International Journal of Social Robotics*, vol. 18, 2026, makale no. 52.
- [2] R. Hasani, M. Lechner, A. Amini, D. Rus, and R. Grosu, "Liquid time-constant networks," in *Proceedings of the AAAI Conference on Artificial Intelligence*, vol. 35, 2021, pp. 7657–7666.
- [3] M. Lechner, R. Hasani, A. Amini, T. A. Henzinger, D. Rus, and R. Grosu, "Neural circuit policies enabling auditable autonomy," *Nature Machine Intelligence*, vol. 2, no. 10, pp. 642–652, 2020.
- [4] J. Schulman, F. Wolski, P. Dhariwal, A. Radford, and O. Klimov, "Proximal policy optimization algorithms," *arXiv preprint arXiv:1707.06347*, 2017.
- [5] C. Chen, Y. Liu, S. Kreiss, and A. Alahi, "Crowd-robot interaction: Crowd-aware robot navigation with attention-based deep reinforcement learning," in *IEEE International Conference on Robotics and Automation (ICRA)*, 2019, pp. 6015–6022.
- [6] J. van den Berg, S. J. Guy, M. Lin, and D. Manocha, "Reciprocal n-body collision avoidance," in *Robotics Research: The 14th International Symposium ISRR*, ser. Springer Tracts in Advanced Robotics. Springer, 2011, vol. 70, pp. 3–19.
- [7] P.-W. Chou, D. Maturana, and S. Scherer, "Improving stochastic policy gradients in continuous control with deep reinforcement learning using the beta distribution," in *Proceedings of the 34th International Conference on Machine Learning (ICML)*, ser. PMLR, vol. 70, 2017.
- [8] M. Alshiekh, R. Bloem, R. Ehlers, B. Könighofer, S. Niekum, and U. Topcu, "Safe reinforcement learning via shielding," in *Proceedings of the AAAI Conference on Artificial Intelligence*, vol. 32, no. 1, 2018.
- [9] A. D. Ames, X. Xu, J. W. Grizzle, and P. Tabuada, "Control barrier function based quadratic programs for safety critical systems," *IEEE Transactions on Automatic Control*, vol. 62, no. 8, pp. 3861–3876, 2017.
- [10] P. Henderson, R. Islam, P. Bachman, J. Pineau, D. Precup, and D. Meger, "Deep reinforcement learning that matters," in *Proceedings of the AAAI Conference on Artificial Intelligence*, vol. 32, 2018.
- [11] R. Agarwal, M. Schwarzer, P. S. Castro, A. C. Courville, and M. G. Bellemare, "Deep reinforcement learning at the edge of the statistical precipice," in *Advances in Neural Information Processing Systems (NeurIPS)*, vol. 34, 2021.