

Kalabalıkta İnsan-Merkezli Navigasyon için SNCP–PPO: Sadık Reprodüksiyon, Ablasyonlar ve Eğitimsiz Güvenlik Kalkanı

Orkun Koray Güngör
Mekatronik Mühendisliği Bölümü
Bursa Teknik Üniversitesi
Bursa, Türkiye
orkun9312@gmail.com

Özet—Bu çalışma, Ao vd.’nin kalabalıkta insan-merkezli hareket planlama için önerdiği SNCP–PPO yaklaşımını bağımsız bir kod tabanında yeniden üretir ve bildirilen yüksek başarı oranına hangi mühendislik kararlarının yaklaştırdığını sistematik olarak inceler. Referans makalenin kullandığı görünmez-robot/ORCA kalabalık rejimi, 15×15 m arena, 1.0 m/s robot hızı ve PPO eğitim hattı kurulduktan sonra, naif uygulama hâlâ challenging senaryoda düşük başarı verir. Bu farkı açıklamak için best-checkpoint yanlılığını dışarıda bırakan çok-tohumlu bir değerlendirme protokolü kullanılır (5 tohum $\times$ 50 bölüm, Wilson güven aralığı, iki-oranlı z testi ve Bonferroni düzeltmesi). Sonuçlar, açığın büyük kısmının ham model kapasitesiyle değil, temsil sadakati ve eğitim dağılımıyla ilgili olduğunu gösterir: ön-MLP gömmesi, yoğunluk müfredatı ve mean+max dikkat havuzlaması $N=10$ başarıyı %61.6’dan %89.6’ya, $N=20$ başarıyı %43.6’dan %79.2’ye çıkarır. Buna karşılık daha büyük NCP düğümleri, çok-başlı dikkat, 6 m algı maskesi ve birleşik çoklu kaldıraç denemeleri yüksek yoğunlukta güvenilir ilerleme sağlamaz; Beta eylem dağılımı yön-doğru fakat istatistiksel olarak kesinleşmeyen bir iyileşme üretir. Son aşamada, öğrenilmiş politikayı değiştirmeden çalışan eğitimsiz bir kısa-horizon eylem kalkanı eklenir. Kilitli v34 Beta politikası üzerine uygulanan bu v38 katmanı, aynı dürist çok-tohumlu protokolde (5 tohum $\times$ 50 bölüm) $N=5/10/15/20$ için %99.6/%99.6/%99.6/%98.8 başarı ve %0.0/%0.0/%0.4/%0.4 çarpışma verir; ham v34’e göre yüksek-yoğunluk kazancı ($N=20$ başarı +12.8 pp, çarpışma –12.8 pp) dört yoğunlukta da Bonferroni-anlamlıdır. Böylece çalışma iki sonuç sunar: saf SNCP–PPO tarafında açığı kapatan ve kapatmayan tasarım kararları ayrıştırılır; sistem tarafında ise kalan çarpışma-kaynaklı hata küçük bir runtime güvenlik katmanıyla pratik olarak azaltılır.

Index Terms—kalabalıkta navigasyon, sosyal robotik, pekiştirmeli öğrenme, PPO, nöral devre politikaları, sıvı zaman-sabitli ağlar, güvenlik filtresi

I. GİRİŞ

Kalabalıkta mobil robot navigasyonu yalnızca en kısa yolu bulma problemi değildir. Robotun hedefe zamanında ulaşması, insanlarla çarpışmaması, kişisel alanı gereksiz yere ihlal etmemesi ve yoğun kalabalıkta ani geometrik değişimlere

tepki verebilmesi gerekir. Bu nedenle problem, klasik yol planlamadan farklı olarak hem dinamik hem de sosyal kısıtlar taşır.

Ao vd. [1], bu problem için Structured Neural Circuit Policy (SNCP) adlı bir yaklaşım önerir. Politika, robot ve yayalar arasındaki etkileşimleri uzay-zamansal bir grafa dönüştürür; robot düğümü, yaya düğümleri ve insan-insan kenarları ayrı Liquid Time-Constant (LTC) / Neural Circuit Policy (NCP) kodlayıcılarından geçirilir; kalabalık özeti dikkat havuzlamasıyla elde edilir; son eylem PPO ile öğrenilir. Makale, challenging senaryoda yaklaşık %94 başarı bildirir.

Bu raporun çıkış noktası basittir: aynı fikri bağımsız bir uygulamada kurduğumuzda ilk sonuçlar bu seviyeye ulaşmadı. Farkın nedeni tek bir hata değildi. Makalede belirtilmeyen NCP kablolaması, eğitim yoğunluğu, algı menzili, yaya modeli ayrıntıları, eylem dağılımı ve checkpoint seçimi gibi çok sayıda karar sonucu etkiliyordu. Bu yüzden çalışmanın ana hedefi yalnızca “en iyi sayıyı” bulmak değil, açığı oluşturan bileşenleri ölçülebilir şekilde ayırmaktır.

Çalışmanın katkıları şunlardır:

- Referans makalenin değerlendirme rejimine yakın bir SNCP–PPO hattı kurulur: ORCA yayalar, görünmez robot, 1.0 m/s robot, paper-standard ve paper-challenging senaryoları.
- Eğitim-içi best checkpoint ölçütünün seçim yanlılığı gösterilir ve model kıyasları çok-tohumlu, istatistiksel olarak denetlenmiş bir protokole bağlanır.
- Temsil sadakati ve eğitim dağılımı düzeltmelerinin açığın büyük kısmını kapattığı; ham kapasite, çok-başlı dikkat, sayısal dikkat ölçekleme ve 6 m algı maskesinin ise yüksek yoğunlukta beklenen ilerlemeyi sağlamadığı gösterilir.
- Son sistem adımı olarak eğitimsiz bir runtime eylem kalkanı eklenir. Bu kalkan yeni bir PPO eğitimi değil, öğrenilmiş deterministik eylem üzerinde kısa-horizon çarpışma filtresidir ve aynı çok-tohumlu protokolde challenging $N=20$ başarısını v30’un %79.2’sinden %98.8’e

çıkarır (çarpmayı pratikte ortadan kaldırır).

II. İLGİLİ ÇALIŞMALAR

Kalabalıkta robot navigasyonu. CrowdNav çizgisindeki çalışmalar, robotun yayalar tarafından görülmediği ve yayaların yalnızca birbirlerinden kaçındığı bir simülasyon rejimi kullanır [2]. Bu rejim, robotun kendi güvenliğini tek başına sağlamasını gerektirdiği için zordur. Referans SNCP çalışması da aynı temel fikri kullanır [1]. Bizim uygulamamızda da robot yayalar için görünmezdir; yayalar ORCA ile birbirlerinden kaçınır, robot ise PPO politikasıyla hareket eder.

Nöral devre politikaları. LTC ağları, girdiye bağlı zaman sabitleriyle sürekli-zamanlı dinamikler öğrenir [3]. NCP'ler bu hücreleri seyrek ve yorumlanabilir bağlantı şemalarıyla birleştirir [4]. SNCP mimarisinin çekiciliği, kalabalık etkileşimini doğrudan büyük bir MLP'ye vermek yerine robot, yaya ve insan-insan ilişkilerini ayrı devrelerle işlemesidir.

Dikkat ve küme havuzlama. Dikkat mekanizması değişken sayıdaki ajanı ağırlıklı ortalama ile özetler [5]. Ancak yüksek yoğunlukta yalnızca ortalama almak, en kritik yayayı seyretebilir. DeepSets [6] ve PointNet [7], küme fonksiyonlarında maksimum havuzlamanın önemli bir bilgi yolu olduğunu gösterir. Bu gözlem, mean+max havuzlama denemesinin temelini oluşturur.

Sınırlı eylem uzayı. PPO çoğunlukla Gauss politika dağılımıyla uygulanır [8]; fakat robot hızları fiziksel sınırlarla kısıtlandığında Gauss örneğini kırmak log-olasılık ve yürütülen eylem arasında uyumsuzluk yaratabilir. Beta dağılımı sınırlı aralığı doğal olarak modellediği için sürekli kontrol problemlerinde önerilmiştir [9]. Bu nedenle Beta eylem dağılımı ayrıca test edilir.

III. PROBLEM TANIMI VE DENEY ORTAMI

Robot, unicycle kinematiğine sahip TurtleBot3 Waffle benzeri bir ajandır. Eylem $a_t = (v_t, \omega_t)$ doğrusal ve açısal hızdan oluşur. Robotun amacı, dairesel yerleşimdeki başlangıç noktasından karşı hedefe ulaşmaktır. Başarılı bölüm, hedefe çarpışmadan ulaşmakla; başarısız bölüm ise çarpışma veya zaman aşımıyla tanımlanır.

Ana değerlendirme senaryosu *paper_challenging*'dir: 15×15 m arena, 1.0 m/s robot hızı, ORCA yayalar ve görünmez robot varsayımı. Yoğunluklar $N = \{5, 10, 15, 20\}$ olarak değerlendirilir. *paper_standard* senaryosu ayrıca 5 yaya ve daha dar zaman bütçesiyle kontrol edilir.

Ödül fonksiyonu hedefe yaklaşmayı, hedefe ulaşmayı, çarpışmadan kaçınmayı ve sosyal baskıyı birleştirir. Sosyal baskı I_{sp} , robotun yayalara olan yakınlığından türetilir. Ancak bu çalışmada asıl vurgu yeni bir ödül tasarlamak değildir; ödül hattı sabit tutulurken mimari, eğitim dağılımı ve güvenlik katmanını etkileri ölçülür.

IV. YÖNTEM


A. SNCP-PPO politikası

Politika üç bilgi kanalını işler. Birincisi robotun kendi durumu ve hedef yönüdür. İkincisi robot-yaya kenarlarıdır: her yaya için görel konum, görel hız ve ilgili geometrik

Tablo I
DENEY REJİMİNİN ANA BİLEŞENLERİ. AMAÇ, REFERANS MAKALENİN DEĞERLENDİRME KOŞULLARINA YAKIN AMA KODDA AÇIKÇA DENETLENEBİLİR BİR KURULUM OLUŞTURMAKTIR.

Bileşen	Kullanılan ayar
Robot modeli	Unicycle, $v_{\max} = 1.0$ m/s
Yaya modeli	ORCA, robot yayalar için görünmez
Ana senaryo	<i>paper_challenging</i> , 15×15 m
Yoğunluklar	$N = 5, 10, 15, 20$
Başarı ölçütü	Hedefe çarpışmadan ulaşma
Hata tipleri	Çarpışma, zaman aşımı
Ana checkpoint	v34 Beta politika; v38'de runtime kalkan

SNCP-PPO mimarisi: v30 sadakat eklentileri ve mimari katkı vurgulu



Şekil 1. SNCP-PPO mimari özeti. Robot, robot-yaya ve insan-insan bilgileri ayrı kodlanır; değişken sayıdaki yaya dikkat ve mean+max havuzlama ile sabit boyutlu eylem temsiline dönüştürülür.

bilgiler kodlanır. Üçüncüsü insan-insan ilişkileridir: yayaların birbirlerine göre hareketleri kalabalık yapısını temsil eder.


Bu kanallar NCP/LTC tabanlı kodlayıcılarla zamansal olarak işlenir. Değişken sayıdaki yaya için elde edilen özellikler önce dikkat havuzlamasına, daha sonra mean+max havuzlamaya verilir. Mean dalı kalabalığın genel eğilimini, max dalı ise en kritik yerel tehdidi taşır. Şekil 1 mimari akışı özetler.

B. Eğitim ve checkpoint seçimi

PPO eğitimi vektörize ortamda yapılır. Başlıca hiperparametreler sabit tutulur; versiyonlar arasındaki farklar mümkün olduğunca tek bir mühendislik kararına indirgenir. Erken sürümlerde eğitim-içi holdout sonucuna göre en iyi checkpoint seçmek kullanışlı görünse de bu ölçüt yanıltıcı: çok sayıda gürültülü değerlendirmenin maksimumu gerçek ortalama olmayacağından yüksek gösterir. Bu nedenle nihai kıyaslarda checkpoint'ın eğitim-içi en iyi skoru değil, bağımsız çok-tohumlu değerlendirme sonucu raporlanır.

C. V38 eylem kalkanı

v38, yeni bir öğrenilmiş politika değildir. Kilitli v34 Beta politikasının deterministik eylemi alınır ve kısa bir sabit-hız öngörüsüyle robot-yaya mesafeleri tahmin edilir. Eğer seçilen eylem öngörü ufkunda çarpışma riski yaratmıyorsa aynen yürütülür. Risk varsa, sınırlı bir aday eylem kümesi taranır ve hedefe ilerleme ile minimum güvenli mesafe arasında daha güvenli olan aday seçilir. Bu işlem yalnızca yürütme zamanında uygulanır; checkpoint ağırlıkları değişmez.



Şekil 2. Checkpoint seçimi yanlışlığı. Tek tek değerlendirme blokları arasında yüksek varyans vardır; yalnızca en iyi bloğa bakmak gerçek ortalamayı yukarı çeker. Bu nedenle sürüm kararları çok-tohumlu havuzlanmış sonuçlarla verilir.

Bu tasarımın amacı PPO politikasını baştan eğitmek değil, teşhis edilen hata kipini doğrudan hedeflemektir: yüksek yoğunlukta başarısızlıkların büyük kısmı zaman aşımı değil çarpışmadır. Dolayısıyla kalkan, “öğrenilmiş sosyal rota”yı koruyup yalnızca çarpışma sınırındaki eylemi düzeltir.

V. DEĞERLENDİRME PROTOKOLÜ

Ana ablasyon protokolünde her yoğunluk için 5 bağımsız değerlendirme tohumu ve tohum başına 50 bölüm kullanılır; toplam 250 bölüm/yoğunluk elde edilir. Başarı ve çarpışma oranları Wilson güven aralığıyla raporlanır; sürüm farkları iki-oranlı z testiyle kontrol edilir; dört yoğunluk için Bonferroni eşiği $\alpha = 0.0125$ olarak alınır. Bu tercih, derin pekiştirmeli öğrenmede tek-tohum ve küçük örneklem sonuçlarının kırılganlığına ilişkin uyarılarla uyumludur [10], [11].

V38 da aynı çok-tohumlu protokolde (5 tohum $\times$ 50 bölüm = 250/yoğunluk) değerlendirilir; böylece önceki ablasyonlarla doğrudan kıyaslanabilir. Ek olarak, ham v34 politikası (C0) ve kalkanlı politika (C1) aynı checkpoint, aynı tohumlar ve aynı bölümler üzerinde karşılaştırılır; bu eşleşme kalkanın etkisini izole eder: model ve eğitim-tohumu sabit, tek değişen yürütme-zamanı kalkanıdır.

VI. SONUÇLAR

A. Açığı kapatan üç karar: ön-MLP, yoğunluk müfredatı ve mean+max

Naif paper-rejim tabanı v26, zaman aşımını büyük ölçüde çözer; fakat başarısızlık çarpışmaya dönüşür ve özellikle yüksek yoğunlukta başarı düşük kalır. Üç karar bu tabloyu belirgin biçimde iyileştirir (Tablo II, Şekil 3). Ön-MLP gömmesi ham kenar özelliklerini NCP’ye daha kullanılabilir bir temsille verir. Yoğunluk müfredatı testte görülen $N = 15$ ve $N = 20$ durumlarını eğitim dağılımına dahil eder. Mean+max havuzlama ise kalabalığın ortalama eğilimi ile en tehlikeli ajan bilgisini ayrı yollarla taşır.

v30’un ayrıntılı metrikleri Tablo III’te verilmiştir. Zaman aşımı tüm yoğunluklarda %0’dır; bu önemli bir ayrımdır. Başarısızlık artık hedefe yetişememekten değil, yüksek yoğunlukta çarpışmadan kaynaklanır. Başarılı bölüm süresi yoğunlukla

Tablo II
TEMEL İLERLEME ÇİZGİSİ: BAŞARI / ÇARPİŞMA (%), 250 BÖLÜM/YOĞUNLUK. V30, ÖĞRENİLMİŞ POLİTİKA TARAFINDAKİ ANA ŞAMPIYON YAPILANDIRMADIR.

N	v26	v27	v28	v30
5	74.8 / 25.2	93.6 / 6.8	94.4 / 5.6	97.2 / 2.8
10	61.6 / 38.4	80.0 / 20.0	87.6 / 12.4	89.6 / 10.4
15	53.2 / 46.8	70.8 / 29.6	79.2 / 20.8	85.6 / 14.4
20	43.6 / 56.4	59.6 / 40.4	73.2 / 27.2	79.2 / 20.8

Tablo III
V30 AYRINTILI METRİKLERİ. BAŞARI WILSON %95 GÜVEN ARALIĞIYLA, NAV SÜRESİ BAŞARILI BÖLÜM ADIMI $\times 0.25$ S OLARAK RAPORLANIR.

N	Başarı [%95 GA]	Çarp.	Z.aş.	Nav (s)	$I_{sp} \times 10^{-3}$
5	97.2 [94.3, 98.6]	2.8	0.0	10.25	10.8
10	89.6 [85.2, 92.8]	10.4	0.0	11.20	10.0
15	85.6 [80.7, 89.4]	14.4	0.0	11.81	8.2
20	79.2 [73.7, 83.8]	20.8	0.0	12.68	7.5

artar; bu da politikanın düz çizgiyle gitmediğini, kalabalığa göre rota değiştirdiğini gösterir.

B. Kapatmayan kararlar: kapasite, çok-başlı dikkat ve algı maskesi


v30’dan sonra altı kaldıraç test edilir. Daha büyük NCP düğümü, daha geniş çıktı temsili, çok-başlı dikkat, daha geniş yoğunluk müfredatı, dikkat sayı-ölçeklemesi, Beta eylem dağılımı ve 6 m algı maskesi ayrı ayrı incelenir. Özet sonuç şudur: ham kapasite eklemek veya algıyı makalenin 6 m bütçesine indirmek kalan açığı kapatmaz. Beta dağılımı doğru yönde görünür; fakat tek eğitim tohumu ve Bonferroni düzeltmesi altında kesin geçiş sağlamaz.

Özellikle 6 m algı maskesi önemlidir. Referans makale challenging senaryoda 6 m algı bütçesi bildirir; bu nedenle uzak yayaları maskelemek ilk bakışta sadakat düzeltmesi gibi görünür. Ancak sonuç ters yöndedir: $N=20$ başarı %79.2’den %69.6’ya düşer, çarpışma %20.8’den %30.4’e çıkar. Bu, kalan farkın “robot çok fazla görüyor” olmasından değil, gördüğü bilgiyi nasıl kullandığından kaynaklandığını düşündürür.

C. V36 ve V37: birleşik ve dikkat-temelli denemelerin olumsuz sonucu


v36, önceki tek tek denenen kaldıraçların çoğunu aynı koşuda birleştirir: geniş NCP, çok-başlı dikkat, dikkat sayı-ölçeklemesi, $N = 10-25$ müfredatı, Beta dağılımı ve 6 m algı maskesi. Bu bilinçli olarak çok-değişkenli bir denemedir. Sonuç negatiftir: birleşik sistem v34’ün yüksek yoğunluk kazanımını koruyamaz; $N=15$ ve $N=20$ ’de başarı düşer, çarpışma artar. Yorum açıktır: tek başına umut veren bazı kararları birleştirmek otomatik olarak daha iyi politika üretmez; özellikle 6 m maske ve aşırı kapasite, Beta’nın faydasını seyreletmiştir.

v37 ise v34 checkpoint’i üzerinde insan-insan niyet geometrisi ve gated attention fikrini hızlı paired probe ile dener. Kapı etkinleşmez ve C1, C0’ı geçemez; düşük yoğunlukta gerileme ve yüksek yoğunlukta çarpışma artışı görülür. Bu nedenle v37



Şekil 3. v26'dan v30'a ilerleme. Ön-MLP, yoğunluk müfredatı ve mean+max havuzlama birlikte başarıyı artırır, çarpışmayı azaltır ve makale hedefiyle aradaki farkı büyük ölçüde kapatır.

Şampiyon (v30) kalabalıkta gerçek yörüngeler — paper_challenging



Şekil 4. v30 yörüngeleri. Robot yoğunluk arttıkça daha uzun ve kavisli rotalar üretir; bu, kalabalığın içinden düz çizgiyle geçme davranışı değil, gerçek kaçınma davranışdır.

full training'e taşınmaz. Bu iki olumsuz sonuç, v38'e geçişin gerekçesidir: yeni bir temsil eklemek yerine, doğrudan kalan çarpışma kipine müdahale etmek daha düşük risklidir.

D. V38: runtime eylem kalkanı


V38, ham v34 deterministik politikasıyla aynı dürüst protokolde karşılaştırılır: aynı checkpoint, aynı 5 tohum ve aynı bölümler; tek fark yürütme-zamanı kalkanıdır (Tablo V). Bu eşleşme, gözlenen farkı doğrudan kalkana atfetmeyi sağlar. Kalkan N=10/15/20'de hem başarıyı yükseltir hem çarpışmayı düşürür ve bu kazanç çarpışmada dört yoğunlukta da Bonferroni-anlamlıdır; yüksek yoğunlukta etki büyüktür

(N=20 başarı +12.8 pp, çarpışma -12.8 pp, Cohen $h \approx 0.55$). Zaman aşımı %0.8 ve altında kaldığı için iyileşme robotu durdurulmaktan değil, çarpışma sınırındaki eylemi düzeltmekten gelir.

Aynı kalkan, önceki şampiyon v30'a göre daha da büyük bir etki verir (N=20 başarı %79.2→%98.8, +19.6 pp; çarpışma %20.8→%0.4, -20.4 pp). Final sistemde başarı N=5/10/15/20 için %99.6/%99.6/%99.6/%98.8, çarpışma %0.0/%0.0/%0.4/%0.4, zaman aşımı %0.8 ve altıdır. Başarılı bölüm uzunluğu yoğunlukla artar (47.2/52.1/57.6/60.1 adım); yani kalkan sosyal rotayı bozmadan yalnızca çarpışma sınırındaki eylemi düzeltir.

Tablo IV
v30 SONRASI KALDIRAÇLAR: BAŞARI / ÇARPIŞMA (%), 250 BÖLÜM/YOĞUNLUK. v34 Beta YÖN-DOĞRU SONUÇ ÜRETİR; DİĞERLERİ YÜKSEK YOĞUNLUKTA v30'U GÜVENİLİR BİÇİMDE GEÇEMEZ.


N	v30	v31 kapasite	v32 N→25	v33 MHA	v34 Beta	v35 6m
5	97.2 / 2.8	92.8 / 7.2	97.6 / 2.8	95.6 / 4.8	96.8 / 2.8	96.8 / 2.8
10	89.6 / 10.4	84.0 / 16.0	94.0 / 6.0	84.4 / 15.6	92.8 / 7.2	89.6 / 10.0
15	85.6 / 14.4	78.8 / 21.2	87.6 / 13.2	76.0 / 24.0	91.2 / 8.8	79.2 / 20.8
20	79.2 / 20.8	72.8 / 27.6	78.8 / 21.2	70.8 / 29.2	86.0 / 13.2	69.6 / 30.4



Şekil 5. v30 sonrası kaldırmaçaların yüksek yoğunluk farkları. Beta doğru yöndedir; kapasite, çok-başlı dikkat ve 6 m maskeleme yüksek yoğunlukta beklenen kazanımı vermez.

Tablo V
v38 EYLEM KALKANI, HAM v34 POLİTİKASINA KARŞI (KALKAN İZOLASYONU: AYNI CHECKPOINT/TOHUM/BÖLÜM). DÜRÜST ÇOK-TOHURLU PROTOKOL, 250 BÖLÜM/YOĞUNLUK; BAŞARI WILSON %95 GA İLE. Δ SÜTUNLARINDA İKİ-ORANLI z TESTİ p -DEĞERİ; BONFERRONI-ANLAMLI ($p < 0.0125$) DEĞERLER KALIN.

N	v34 baş.	v38 başarı [%95 GA]	Δ baş. (p)	v34 çarp.	v38 çarp.	Δ çarp. (p)	v38 z.aş.
5	96.8	99.6 [97.8, 99.9]	+2.8 (0.019)	2.8	0.0	-2.8 (0.008)	0.4
10	92.8	99.6 [97.8, 99.9]	+6.8 (10^{-4})	7.2	0.0	-7.2 ($< 10^{-4}$)	0.4
15	91.2	99.6 [97.8, 99.9]	+8.4 ($< 10^{-4}$)	8.8	0.4	-8.4 ($< 10^{-4}$)	0.0
20	86.0	98.8 [96.5, 99.6]	+12.8 ($< 10^{-4}$)	13.2	0.4	-12.8 ($< 10^{-4}$)	0.8



Şekil 6. Algı maskesi sonucu. 6 m havuz maskesi yüksek yoğunlukta başarıyı düşürür ve çarpışmayı artırır; uzak yayalar gürültü değil, erken kaçınma için yararlı sinyaldir.

E. Standard senaryo


Challenging rejimde ana hata çarpışmayken, standard senaryoda hata karakteri farklıdır. v30 standard senaryoda %85.6

başarı, %3.6 çarpışma ve %10.8 zaman aşımı verir. Bu, standard senaryodaki açığın daha çok zaman bütçesi ve checkpoint seçimiyle ilişkili olduğunu gösterir. Dolayısıyla tek bir çözüm tüm senaryoları aynı biçimde düzeltmez: challenging için güvenlik filtresi etkiliyken, standard için zaman-bütçesi duyarlı seçim veya ince ayar gerekir.


VII. TARTIŞMA

Sonuçlar üç ders verir. Birincisi, reproduksiyon problemi tek bir hiperparametre hatası değildir. Makalede belirtilmeyen küçük tasarım kararları, özellikle temsili NCP'ye nasıl verildiği ve eğitim yoğunluğunun hangi aralığı kapsadığı, sonucu büyük ölçüde değiştirir.

İkincisi, daha büyük model her zaman daha iyi değildir. v31 ve v33 kapasiteyi artırır; fakat yüksek yoğunlukta v30'u geçemez. Bu, sorunun parametre sayısından çok temsili doğru özetlenmesiyle ilgili olduğunu gösterir. Mean+max havuzlama



Şekil 7. v38 eylem kalkanı (dürüst 5-tohum havuz, 250 bölüm/yoğunluk). Sol: başarı; sağ: çarpışma. Kalkan, v34 ve v30 politikalarının yüksek-yoğunluk çarpışmasını pratikte sıfıra indirirken başarıyı yükseltir; hata çubukları ± 1.96 SE.



Şekil 8. v38 kalkanlı yörüngeler (N=10 ve N=20, paper_challenging). Kalkan sosyal rotayı korur, yalnızca çarpışma sınırındaki eylemleri düzeltir.

küçük ama etkili bir değişikliktir; çünkü yalnızca ortalamayı değil, en riskli yerel durumu da taşır.

Üçüncüsü, v38 saf öğrenilmiş politika tartışmasını sistem güvenliği tartışmasından ayırır. Saf SNCP-PPO politikası hâlâ yoğun kalabalıkta çarpışma sınırında hata yapabilir. Fakat bu hata, kısa-horizon analitik bir kontrol filtresiyle büyük ölçüde düzeltilebilir. Bu sonuç pratik robotik açıdan önemlidir: güvenlik katmanı, eğitilmiş politikanın yerine geçmez; onu daha güvenli bir yürütme sistemine dönüştürür.

Bu ayırım raporun ana yorumudur. Eğer amaç makaledeki mimariyi saf biçimde yeniden üretmekse, v30/v34 çizgisi ve olumsuz ablasyonlar önemlidir. Eğer amaç çalışan bir sistem çıkarmaksa, v38 kalkanı daha doğrudan ve daha güvenilir bir mühendislik çözümüdür.

VIII. SINIRLAMALAR

Bu çalışmanın bazı sınırları vardır. İlk olarak, eğitimler çoğunlukla tek eğitim tohumu ile yapılmıştır; değerlendirme çok-tohumlu olsa da eğitim varyansı tam ölçülmemiştir. İkinci olarak, v38 eylem kalkanı yayaların kısa-horizon sabit-hız hareketini varsayar ve değerlendirmede ortamın gerçek yaya konum/hızlarını kullanır; gerçek bir robotta bu bilgiler algılama gürültüsüyle gelir. Üçüncü olarak, v38 yeni bir checkpoint değildir; dolayısıyla saf SNCP mimarisinin öğrenme başarısı olarak değil, runtime güvenlik katmanı olarak raporlanır. Dördüncü olarak, ORCA parametreleri ve makaledeki bazı eğitim

ayrıntıları tam verilmediği için reproduksiyon açığının bir kısmı kaçınılmazdır. Son olarak, standard senaryodaki zaman aşımı açığı v38 ile doğrudan hedeflenmemiştir.

IX. SONUÇ

Bu rapor, SNCP-PPO tabanlı kalabalık navigasyon problemini baştan sona deneysel olarak ayırıştırır. Önce referans makalenin rejimine yakın bir uygulama kurulumu; sonra best-checkpoint yanlılığı dışarıda bırakılarak çok-tohumlu kıyas protokolü uygulanır. Sonuçlar, açığı kapatan kararların ön-MLP, yoğunluk müfredatı ve mean+max havuzlama gibi temsil/egitim dağılımı kararları olduğunu; ham kapasite, çok-başlı dikkat ve 6 m algı maskesinin yüksek yoğunlukta beklenen faydayı sağlamadığını gösterir. Beta eylem dağılımı umut verici ama tek-tohumda kesinleşmeyen bir iyileşmedir. Son sistem adımı olan v38 eylem kalkanı ise öğrenilmiş politikayı değiştirmeden çarpışma-kaynaklı kalan hatayı büyük ölçüde azaltır ve aynı çok-tohumlu protokolde N=20 challenging başarısını v30'un %79.2'sinden %98.8'e çıkarır (çarpışma %20.8→%0.4, Bonferroni-anlamlı). Böylece çalışma hem reproduksiyon açısından hangi kararların kritik olduğunu, hem de pratik sistem açısından küçük bir güvenlik filtresinin neden etkili olduğunu gösterir.

KAYNAKLAR

- [1] T. Ao, H. Li, Y. Tian *et al.*, "Human-centric motion planning in crowded spaces: A structured neural circuit approach with social interaction-awareness," *International Journal of Social Robotics*, vol. 18, 2026, makale no. 52.
- [2] C. Chen, Y. Liu, S. Kreiss, and A. Alahi, "Crowd-robot interaction: Crowd-aware robot navigation with attention-based deep reinforcement learning," in *IEEE International Conference on Robotics and Automation (ICRA)*, 2019, pp. 6015–6022.
- [3] R. Hasani, M. Lechner, A. Amini, D. Rus, and R. Grosu, "Liquid time-constant networks," in *Proceedings of the AAAI Conference on Artificial Intelligence*, vol. 35, 2021, pp. 7657–7666.
- [4] M. Lechner, R. Hasani, A. Amini, T. A. Henzinger, D. Rus, and R. Grosu, "Neural circuit policies enabling auditable autonomy," *Nature Machine Intelligence*, vol. 2, no. 10, pp. 642–652, 2020.
- [5] A. Vaswani, N. Shazeer, N. Parmar, J. Uszkoreit, L. Jones, A. N. Gomez, L. Kaiser, and I. Polosukhin, "Attention is all you need," in *Advances in Neural Information Processing Systems (NeurIPS)*, 2017.
- [6] M. Zaheer, S. Kottur, S. Ravanbakhsh, B. Póczos, R. Salakhutdinov, and A. J. Smola, "Deep sets," in *Advances in Neural Information Processing Systems (NeurIPS)*, 2017, pp. 3391–3401.

- [7] C. R. Qi, H. Su, K. Mo, and L. J. Guibas, "Pointnet: Deep learning on point sets for 3d classification and segmentation," in *IEEE Conference on Computer Vision and Pattern Recognition (CVPR)*, 2017.
- [8] J. Schulman, F. Wolski, P. Dhariwal, A. Radford, and O. Klimov, "Proximal policy optimization algorithms," *arXiv preprint arXiv:1707.06347*, 2017.
- [9] P.-W. Chou, D. Maturana, and S. Scherer, "Improving stochastic policy gradients in continuous control with deep reinforcement learning using the beta distribution," in *Proceedings of the 34th International Conference on Machine Learning (ICML)*, ser. PMLR, vol. 70, 2017.
- [10] P. Henderson, R. Islam, P. Bachman, J. Pineau, D. Precup, and D. Meger, "Deep reinforcement learning that matters," in *Proceedings of the AAAI Conference on Artificial Intelligence*, vol. 32, 2018.
- [11] R. Agarwal, M. Schwarzer, P. S. Castro, A. C. Courville, and M. G. Bellemare, "Deep reinforcement learning at the edge of the statistical precipice," in *Advances in Neural Information Processing Systems (NeurIPS)*, vol. 34, 2021.