

Kalabalıkta İnsan-Merkezli Navigasyonun Sadık Bir Reprodüksiyonu: SNCP–PPO Açığını Ne Kapatır, Ne Kapatmaz?

Orkun Koray Güngör
Bilgisayar Mühendisliği Bölümü
Üniversite Adı, Şehir, Türkiye
Haziran 2026

Özet—Yayımlanmış güçlü sonuçları bağımsız olarak yeniden üretmek, makalelerin tasarım kararlarının çoğunu belirtmemesi nedeniyle zordur. Bu çalışma, kalabalıkta insan-merkezli navigasyon için SNCP–PPO mimarisini makalenin değerlendirme rejiminde (dağılık yayalar, 15×15 m arena, görünmez robot, ORCA kalabalık, 1.0 m/s) sadık biçimde yeniden kurar ve bildirilen %94 “challenging” başarısına olan açığı *neyin kapatıp neyin kapatmadığını* yoğunlukla tek-değişkenli ablasyonlarla ayırıştırır (v32 ve v34 bilinçli olarak iki-değişkenlidir). Tüm kıyasları, eğitim-içi “best” ölçütünün seçim-saplı olduğunu gösterdikten sonra, dürüst bir çok-tohumlu protokole (5 tohum $\times$ 50 bölüm = 250 bölüm/yoğunluk; Wilson güven aralığı, iki-oranlı z , Bonferroni) bağlarız. Üç *sadakat düzeltmesi* (Denklemler 11 ön-MLP gömmesi, yoğunluk müfredatı) ve bir *mimari katkı* (mean+max dikkat havuzlaması) $N=10$ yayada başarıyı %61.6’dan %89.6’ya, $N=20$ ’de %43.6’dan %79.2’ye çıkarır ve çarpışmayı 2.7–9.0 kat düşürür; buna karşın, benimsenen bu yapılandırmanın üzerine denenen altı model kaldıracından *beşi* (ek kapasite, çok-başlı dikkat, algı-menzili maskesi vb.) onu yüksek yoğunlukta geçemez; yalnızca Beta eylem dağılımı yön-doğru bir iyileşme gösterir ($N=10/15/20$ ’de v30’u nokta-tahminle geçer; $N=5$ ’te eşdeğer olduğundan tüm-yoğunluk Pareto üstünlüğü ve ön-kayıtlı geçiş ölçütü sağlanmaz) ancak tek-tohum gücüyle Bonferroni eşliğini aşamaz. En çarpıcı bulgu, robotun algısını makalenin kendi 6 m bütçesine indirmenin açığı *kapatmak yerine genişletmesidir* ($N=20$ %79.2 $\rightarrow$ %69.6): kalan açık “robot ne kadar görüyor” ile değil, “gördüğünü nasıl kullanıyor” (temsili kullanımı) ile ilgilidir.

Index Terms—kalabalıkta navigasyon, pekiştirmeli öğrenme, nöral devre politikaları, sıvı zaman-sabitli ağlar, reproduksiyon, dikkat havuzlaması

I. GİRİŞ

Kalabalık ortamlarda hareket planlama, bir mobil robotun hedefe *hızlı* ulaşması ile çevredeki insanların *konforunu* koruması arasındaki çok-amaçlı bir gerilimdir. Referans aldığımız çalışma, Ao vd. [1], bu problemi *Yapısal Nöral Devre Politikası* (Structured Neural Circuit Policy, SNCP) ile çözer: insan-robot etkileşimini uzay-zamansal bir grafa dönüştürür, üç ayrı Sıvı Zaman-Sabitli (Liquid Time-Constant, LTC) [2] nöral devre [3] kodlayıcı ile işler, dikkat havuzlamasıyla kalabalığı tek bir vektöre indirger ve PPO [4] ile uçtan uca eğitir. Robot eylemi $a_t = (\omega_t, v_t)$ bir tekerlekli (unicycle) modeldir.

Kaynak kodu, eğitim notebook’u ve makale kaynağı (L^AT_EX): <https://github.com/heimdilon/snep-ppo-crowdnav>

Makale, standart senaryoda %99.5, challenging senaryosunda %94 başarı bildirir.

Bu sonucu *bağımsız bir uygulamada* yeniden üretmek beklenenden zordur. Mimari bloklar, ödül fonksiyonu, yaya modeli (ORCA [5]) ve PPO hattı makaleyle eşleşmesine rağmen, naif bir uygulama challenging %94’ün çok altında kalır. Bunun iki nedeni vardır. Birincisi, makale en az 12 değişkeni (NCP kablolaması, eylem aralıkları, eğitim bütçesi, müfredat, ORCA parametreleri, vb.) belirtmez; ikincisi, eğitim-içi “en iyi” (best holdout) ölçütü, çok sayıda gürültülü değerlendirmenin maksimumu olduğundan *yukarı yönlü saplıdır* ve sürüm kıyaslarını yanıltır.

Bu çalışmanın amacı, “%94’e neden ulaşamıyor?” sorusunu spekülasyondan çıkarıp *ölçülebilir* bileşenlere ayırıştırmaaktır. Vardığımız cevap nettir: açığın yarından çoğu *sadakat düzeltmeleriyle* (temsili + eğitim dağılımı) kapanır, ancak ham kapasite, alternatif dikkat/dağılım veya algı menzili eklemekle kapanmaz — yani kalan açık “ne kadar algılandığı” değil, “algılananın nasıl kullanıldığı” sorudur. Katkılarımız:

- **Sadık, rejim-eşlenik bir reproduksiyon** ve makalede belirtilmeyen 12 değişkenin açık denetimi (Bölüm III, Tablo II).
- **Dürüst bir çok-tohumlu değerlendirme protokolü:** best-holdout seçim sapması gösterilir; tüm kıyaslar 250 bölüm/yoğunluk + Wilson %95 GA + iki-oranlı z + Bonferroni ile yapılır (Bölüm III-D, Şekil 3).
- **Açığın yarından çoğunu kapatan iki sadakat düzeltmesi ve bir mimari katkı:** ön-MLP gömmesi ve yoğunluk müfredatı (sadakat) ile mean+max havuzlaması (DeepSets/PointNet-esinli kendi katkımız); $N=10$ ’da %61.6 $\rightarrow$ %89.6, tek-değişkenli atıf (Bölüm V-B, Şekil 4).
- **Kalan açığı sınırlayan altı kaldıraç ablasyonu.** Beşi şampiyonu yüksek yoğunlukta geçemez; altıncısı (Beta eylem dağılımı) yön-doğrudur ama tek-tohumda Bonferroni-altı kalır. Özellikle, robotun algısını makalenin 6 m bütçesine indirmek açığı *genişletir*; bu, açıklamayı “ne kadar algılıyor”dan “algıladığını nasıl kullanıyor”a kaydırır (Bölüm V-E, Şekil 7).

II. İLGİLİ ÇALIŞMALAR

Kalabalıkta navigasyon ve etkileşim. Sosyal-farkında navigasyon literatürünün önemli bir kolu, robotu kalabalığa görünmez kabul eden ve yayaları yalnızca birbirinden kaçınan ORCA ajanları olarak modelleyen CrowdNav rejimini [6] kullanır. Bu kurulum, robotu kendi kaçınma sorumluluğunu tek başına taşımaya zorladığından zorludur. Referans çalışma [1] de bu rejimi benimser; biz de sadakat için aynı görünmez-robot/ORCA ayarını koruruz.

Nöral devre politikaları. LTC ağları [2], sürekli-zamanlı ve girdiye bağlı zaman sabitleriyle ifade gücü yüksek dinamik sistemlerdir; Nöral Devre Politikaları (NCP) [3] bunları *seyrek*, C. elegans-esinli bir bağlantı topolojisiyle birleştirir. Referans mimari bu bileşenleri kullandığını belirtir ancak somut kablolama (nöron sayısı, seyreklik) vermez; biz AutoNCP kablolamasını mühendislik seçimi olarak işaretleriz.

Küme-değişmez havuzlama. Değişken sayıda yayayı tek bir özet vektöre indirgemek, permütasyona değişmez bir küme fonksiyonu gerektirir. Dikkat havuzlaması [7] öğrenilmiş bir ağırlıklı ortalama sağlarken, DeepSets [8] küme-değişmez (permütasyona bağımsız) havuzlamayı kurar; PointNet [9] ise *maksimum* havuzlamanın kardinaliteye dayanıklılığını gösterir. Bizim en etkili sadakat-dışı düzeltmemiz (mean+max), tam da bu içgörüyü dayanır: yoğun kalabalıkta saf dikkat ortalaması en tehditkâr ajayı seyrektir.

Eylem dağılımları. Sınırlı kontrol uzayında Gauss politikasının kırılması sınır-sapması yaratır; Beta dağılımı [10] bu sınırı doğal biçimde modeller. Bu alternatifi de bir ablasyon olarak deneriz.

III. YÖNTEM

A. Politika mimarisi

Politika ağı (Şekil 1), makalenin anlamsal bölümlerini izler. Robot düğümü bir MLP ile 128 boyuta gömülür (Denklem 14). Zamansal ve uzaysal kenarlar birer LTC ile işlenir; kablolama, makalede verilmeyen bir mühendislik seçimi olarak *seyrek* AutoNCP topolojisidir (zamansal 32 nöron/16 motor, uzaysal 48/24, füzyon düğümü 128/48; ~ 90 seyreklik). Dikkat havuzlaması, her yayanın uzaysal özniteliğini robot/zaman anahtarına göre ağırlıklandırır:

$$\alpha^t = \text{softmax}\left(\frac{1}{\sqrt{d_k}} Q^t (K^t)^\top\right), \quad u_{\text{att}}^t = (M_{r-h}^t)^\top \alpha^t, \quad (1)$$

burada $d_k = 64$. Füzyon düğümü NCP'si robot (128) + zaman (256) + dikkat çıktısını birleştirir; aktör-kritik başı (ω, v) ve değeri üretir (Denklem 16).


B. Ödül fonksiyonu

Çok amaçlı ödül üç terimden oluşur, $r^t = r_g^t + r_c^t + r_s^t$:

$$r_g^t = \begin{cases} 20, & \|p^t - p_g\| < p'_{\text{robot}} \\ 2(\|p^{t-1} - p_g\| - \|p^t - p_g\|), & \text{aksi} \end{cases} \quad (2)$$

$$r_c^t = \begin{cases} -20, & d_{\min} < d_{\text{col}} \\ 0, & \text{aksi} \end{cases} \quad r_s^t = -2 I_{\text{sp}}, \quad (3)$$

SNCP-PPO mimarisi: v30 sadakat eklentileri ve mimari katkı vurgulu



Şekil 1. SNCP-PPO politika mimarisi. Şampiyon (v30) iki sadakat/yapı eklentisini içerir: kırmızı, makalenin Denklem 11 ön-MLP gömmesi (ham kenar girdisi NCP'den önce 256 boyuta yükseltilir); mor, mean+max dikkat havuzlaması (öğrenilmiş ağırlıklı ortalamaya kardinaliteye-dayanıklı bir maksimum dalı eklenir).

Algorithm 1 SNCP-PPO: yoğunluk müfredatı + holdout-best

- 1: Politikayı π_θ ve değeri V_ϕ sıfırdan başlat
- 2: $\theta^* \leftarrow \theta$; $m^* \leftarrow -\infty$ ▷ en iyi checkpoint
- 3: **for** $k = 1 \dots K$ (güncelleme penceresi) **do**
- 4: $N \sim U(10, 20)$ ▷ yoğunluk müfredatı (v28+)
- 5: 16 paralel ortamda N yaya ile rollout topla
- 6: GAE avantajları; PPO clip kaybı ($\epsilon=0.2$) ile θ, ϕ güncelle
- 7: **if** $k \bmod K_{\text{eval}} = 0$ **then**
- 8: $m \leftarrow \min(\text{holdout}_{\text{std}}, \text{holdout}_{\text{chal}})$
- 9: **if** $m > m^*$ **then**
- 10: $m^* \leftarrow m$; $\theta^* \leftarrow \theta$
- 11: **end if**
- 12: **end if**
- 13: **end for**
- 14: **return** θ^* ▷ değerlendirme bu ağırlıkları kullanır

burada sosyal baskı indeksi $I_{\text{sp}} \in [0, 1]$, komşu yayaların ters-mesafe ağırlıklı *normalize* ortalamasıdır (makale Denklem 5–7). Reprodüksiyon sürecinde bu terimin normalize edilmemesi ve kırılmış bir uygulama hatası içerdiği bulunmuş ve makaledeki forma düzeltilmiştir.

C. Eğitim ve değerlendirme rejimi

Senaryo *paper_challenging* (dağınık yayalar, 15 × 15 m arena, algı yarıçapı 6 m). Robot geçişi $(0, -4) \rightarrow (0, 4)$, yani 8 m. Robot hızı 1.0 m/s; yayalar ORCA, hız paritesi 1.0 m/s, görünmez-robot rejimi. Bütçe per-senaryo (*challenging* 50 s, standard 12.5 s) ortamdan türetilir; çarpışma eşiği $d_{\text{col}} = 0.3$ m; öğrenme oranı 10^{-4} ; PPO clip 0.2, $\gamma = 0.99$, $dt = 0.25$ s. Eğitim 2.5M adım, 16 paralel ortam × 128 ufuk, sıfırdan (taklit ısıtması yok). Tüm eğitimler Google Colab A100 GPU'sunda sürüm başına ~ 3 –4 saat sürer; değerlendirme belirlenimci ve CPU üzerinde dakikalar mertebesinde.

D. Dürüst çok-tohumlu protokol

Politika belirlenimci (deterministic) modda çalıştırılır (eylem = ortalama). Sürüm kıyasları için her yoğunlukta

Tablo I
MAKALENİN SNCP-PPO İÇİN BİLDİRDİĞİ HEDEF METRİKLER.

Senaryo	Başarı	Çarpışma	Nav-süre
Standard (5 yaya)	0.995	0.005	10.39 s
Challenging (10–20)	0.94	0.04	15.92 s

Tablo II
MAKALEDE *belirtilmeyen* VE BİZİM MÜHENDİSLİK SEÇİMİ OLARAK İŞARETLEDİĞİMİZ BAŞLICA DEĞİŞKENLER.

Kategori	Belirtilmemiş değişken
Mimari	uzay-kenarı gömme boyutu; NCP kabloları (units/sparsity/motor)
Eylem	doğrusal hız aralığı; $\omega_{\max}$; geri hareket; sim ivme
Yaya	ORCA parametreleri; hedefe varınca davranış (durma/respawn)
Eğitim	challenging zaman bütçesi; toplam adım; paralel ortam; müfredat

Makale-içi çelişkiler: algı menzili (Tablo 1: 3 m vs §5.1.2: 4/6 m); t_{lim} (Tablo 1 standard 12.5 s vs Tablo 3 challenging nav-süre 15.92 s).


(N=5/10/15/20) **5 tohum** $\times$ **50 bölüm** = 250 **bölüm** havuzlanır. Bir oranın $\hat{p} = k/n$ %95 güven aralığı, küçük örnek ve uç oranlarda sağlam olan *Wilson* aralığıdır:

$$\frac{\hat{p} + \frac{z^2}{2n} \pm z\sqrt{\hat{p}(1-\hat{p})/n + z^2/4n^2}}{1 + z^2/n}, \quad z=1.96. \quad (4)$$


İki sürümün farkı için havuzlanmış iki-oranlı z -testi ve Cohen $h = 2(\arcsin\sqrt{p_1} - \arcsin\sqrt{p_2})$ etki büyüklüğü raporlanır. Dört yoğunlukta çoklu karşılaştırma yapıldığından anlamlılık eşiği Bonferroni ile $\alpha = 0.05/4 = 0.0125$ alınır. Bir kaldıracın “yardımcı” sayılması için önceden-kayıtlı kural: yüksek-N (N=15/20) başarısı *artmalı* ve/veya çarpışması *düşmeli* (Bonferroni-anlamlı), N=5/10’da gerileme olmamalı ve zaman aşımı 0 kalmalıdır. Bu çok-tohumlu, etki-büyüklüğü ve aralık-temelli raporlama, derin RL’de tekrarlanabilirlik ve istatistiksel titizlik çağrılarını izler [11], [12]. Başarı ve çarpışma ayrı önceden-kayıtlı test aileleri sayılır (her biri dört yoğunlukta düzeltilir); sekizini tek aile kabul eden daha katı eşikte (0.05/8) de hüküm değişmez. Sürümler aynı tohumları paylaştığından bölümler *eşleştirilmiştir*: bağımsız z bu nedenle tutucudur, eşleştirilmiş bir test (McNemar) daha güçlü olurdu; ancak havuzlanmış kayıt per-episode eşleşme tutmadığından bu sonradan uygulanamaz (gelecek çalışma).

IV. MAKALE İLE BİREBİR KARŞILAŞTIRMA

Sadık bir reproduksiyon iddiası, hangi değişkenlerin eşleştiğinin ve hangilerinin makalede hiç verilmediğinin açık bir denetimini gerektirir. Mevcut uygulamamızdaki her değişkeni makaledeki karşılığıyla karşılaştırdık (Tablo III); kategori bazında özet Şekil 2’dedir. Yaklaşık 28 değişken eşleşir, 5’i farklı/kısmîdir ve **12 değişken makalede hiç belirtilmemiştir** — bunlar bizim mühendislik seçimlerimizdir (Tablo II). Bu belirsizlikler, reproduksiyon açığının bir kısmının *kaçınılmaz*



Şekil 2. Makale ile karşılaştırmanın kategori bazında özeti. Yeşil: eşleşiyor; kırmızı: farklı/kısmî; turuncu: makalede belirtilmemiş. Belirtilmeyen değişkenlerin çoğu mimari kabloları, eylem aralıkları ve eğitim/değerlendirme bütçesidir.



Şekil 3. N=10’da seçim sapması. Gri noktalar bağımsız tohum bloklardır (gerçek v30 değerleri); mavi bant dürüst ortalamasının ± 1.96 SE (Wald) aralığıdır. Kırmızı yıldız bu beş bloğun *maksimumudur* (seçim sapmasının bir alt sınırı; eğitimin onlarca eval’inden kaydettiği gerçek “best” daha da yüksektir). Tüm kıyaslar artık çok-tohumludur.

olduğunu gösterir: aynı algoritmayı yazsak bile bu 12 seçim farklı olabilir.

V. SONUÇLAR

A. Metodoloji: “best holdout” seçim-saplıdır

Eğitim sırasında “best” checkpoint, holdout genel-min ölçütü yeni bir maksimuma ulaştığında kaydedilir; ancak her holdout değerlendirmesi *farklı* bir tohum kümesi kullanır ve her biri (50 bölüm) yalnızca $SE \approx 4-7$ puanlık bir tahmindir; 2.5M boyunca yapılan onlarca böyle değerlendirmenin *maksimumu* yukarı yönlü saplıdır. Şekil 3 bunu şampiyonun kendi beş tohum bloğuyla somutlaştırır: blok başarıları %86–94 arasında değişir (havuz ortalaması %89.6) ve yalnız bu beş bloğun maksimumu (%94) bile ortalamadan +4.4 pp yukarıdadır — eğitim onlarca holdout değerlendirmesi yaptığından kaydedilen “best” daha da saplıdır. Bu nedenle tüm sürüm kıyasları çok-tohumlu havuzlanmış orandan gelir; eğitim-içi “best” sayıları rapor edilmez.

B. Açığı kapatan iki sadakat düzeltmesi ve bir mimari katkı

Naif taban (v26) makale rejimini kurar ve zaman aşımını her yoğunlukta sıfırlar; başarısızlık tamamen çarpışmaya in-

Tablo III

DEĞİŞKEN-BAZINDA KARŞILAŞTIRMA (PDF’TEN DOĞRULANDI). **E**: EŞLEŞİYOR; **F**: FARKLI/KISMİ; **B**: MAKALEDE BELİRTİLMEMİŞ (MÜHENDİSLİK SEÇİMİMİZ).

Değişken	Makale	Bizde (v30)	Durum
<i>Ortam / senaryo</i>			
Challenging arena	15 × 15 m	15 × 15 m	E
Algı menzili (chal)	6 m (§5.1.2)	tüm yayalar (maskelenmez [†])	F
Robot geçişi	(0, -4) → (0, 4) = 8 m	8 m	E
Çarpışma eşiği d_{col}	0.3 m	0.3 m	E
Robot hızı (sim)	1.0 m/s	1.0 m/s	E
Challenging yaya	10–20	eğitim $U(10, 20)$; eval 5–20	E
Süre bütçesi	std 12.5 s (Tablo 1)	std 12.5 / chal 50 s	B
<i>Robot kinematigi / yaya</i>			
Eylem uzayı	(ω, v) unicycle (Eq 16)	(ω, v) unicycle	E
Doğrusal hız aralığı	belirtilmemiş	[0, 1.0] m/s	B
Açısal hız ω_{max}	belirtilmemiş	1.8 rad/s	B
Yaya modeli	ORCA	ORCA	E
Görünmez robot	evet	evet	E
ORCA parametreleri	belirtilmemiş	varsayılan seçim	B
<i>Ödül / mimari</i>			
r_g, r_c, r_s (Eq 18–20)	20 / -20 / -2 I_{sp}	aynı	E
I_{sp} (Eq 5–7)	normalize ağırlıklı ort.	normalize (düzeltildi)	E
Gömme boyutları	robot 128, zaman 256, d_k 64	aynı	E
Dikkat ölçeği (Eq 13)	$n/\sqrt{d_k}$	$1/\sqrt{d_k}$ (n-ölçeği v29’da denendi)	F
Eq 11 ön-MLP	var	var (v27)	E
NCP kabloları	belirtilmemiş	AutoNCP (units/sparsity)	B
<i>RL / değerlendirme</i>			
PPO clip / γ / lr	0.2 / 0.99 / 10^{-4}	aynı	E
Toplam eğitim bütçesi	belirtilmemiş	2.5 M adım	B
Test örneği	500/yoğunluk	250 (5 tohum×50)	F
Değerlendirme	tek model, 500 test	5 tohum × 50, çok-tohumlu	F

[†]Makale algıyı 6 m ile sınırlar; bizim gözlemimiz tüm yayaları içerir. Bu uyumsuzluk Bölüm V-E’te v35 ile doğrudan sınanır.

dirgenir, ancak dürüst başarı düşüktür (N=10 %61.6). İki tek-değişkenli sadakat düzeltmesi ve bir mimari katkımız art arda uygulanır (Tablo IV, Şekil 4):

- 1) **v27 — ön-MLP gömmesi (Eq. 11)**. Ham 2/6 boyutlu kenar girdisi NCP’ye girmeden önce bir MLP ile gömülür. Her yoğunlukta %16–19 puanlık kazanç; N=10 %61.6 → %80.0.
- 2) **v28 — yoğunluk müfredatı**. Eğitim yoğunluğu sabit N=10 yerine $N \sim U(10, 20)$ örneklenir (makale 10–20 arasında eğitir). Yüksek yoğunlukta büyük kazanç; N=20 %59.6 → %73.2.
- 3) **v30 — mean+max havuzlaması (mimari katkımız)**. Bir sadakat düzeltmesi değil, DeepSets/PointNet içgörü-süne dayanan bir tasarım seçimidir: dikkatin öğrenilmiş ağırlıklı ortalamasına kardinaliteye-dayanıklı bir maksimum dalı eklenir. v28’i her yoğunlukta *nokta-tahminle zayıf domine eder* (başarı $\geq$, çarpışma $\leq$, sıfır gerileme); en güçlü etki N=15’tedir (+6.4 pp başarı, $p \approx 0.06$) ve Bonferroni-anlamlı *değildir* — ancak tutarlı, gerilemesiz eğilim bunu benimsediğimiz yapılandırma yapar. N=10 %89.6, N=20 %79.2.

Birlikte bu üç değişiklik N=10 açığını (makaleye göre 32 pp) yaklaşık 4 pp’ye indirir ve yüksek yoğunluk düşüşünü belirgin biçimde yumuşatır.


Tablo IV

İKİ SADAKAT DÜZELTMESİ (v27, v28) VE MEAN+MAX KATKIMIZ (v30):
DÜRÜST ÇOK-TOHURLU BAŞARI / ÇARPIŞMA (%), 250
BÖLÜM/YOĞUNLUK. ZAMAN AŞIMI TÜM SÜRÜMLERDE %0. **v30 =**
BENİMSENEN YAPILANDIRMA (NOKTA-TAHMİN LİDERİ; v28’e
ÜSTÜNLÜĞÜ BONFERRONI-ANLAMLILIK DEĞİL).

N	v26 taban	v27 +ön-MLP	v28 +müfr.	v30 +m+m
5	74.8 / 25.2	93.6 / 6.8	94.4 / 5.6	97.2 / 2.8
10	61.6 / 38.4	80.0 / 20.0	87.6 / 12.4	89.6 / 10.4
15	53.2 / 46.8	70.8 / 29.6	79.2 / 20.8	85.6 / 14.4
20	43.6 / 56.4	59.6 / 40.4	73.2 / 27.2	79.2 / 20.8

C. Şampiyonun ayrıntılı metrikleri

Tablo V, benimsenen yapılandırmanın (v30) tüm metriklerini Wilson %95 GA ile birlikte verir. Üç gözlem: (i) zaman aşımı her yoğunlukta %0 — challenging açığı tamamen *çarpışma* kaynaklıdır; (ii) nav-süre yoğunlukla 10.3 → 12.7 s aralığında *artar* (makalenin 15.92 s’inin altında; robot 1.0 m/s ile verimli güzergâhlar) ve sabit kalmaz — bu, gerçek bir kaçınmaya işaret eder, beeline’a değil; (iii) sosyal baskı I_{sp} düşüktür (≤ 0.011).



Şekil 4. Üç sadakat düzeltmesi makale hedefine doğru tırmanır. *Sol*: başarı; *sağ*: çarpışma. v26 (gri) tabanından v30 (mavi, şampiyon) noktasına her yoğunlukta tutarlı iyileşme; yeşil kesikli çizgi makalenin challenging hedefidir. Kalan açık yüksek yoğunlukta yoğunlaşır.

Tablo V

ŞAMPİYON (v30) AYRINTILI METRİKLERİ: DÜRÜST ÇOK-TOHURLU, 250 BÖLÜM/YOĞUNLUK. BAŞARI WILSON %95 GA İLE; NAV-SÜRE = BAŞARILI BÖLÜM ADIMI $\times 0.25$ S; I_{sp} SOSYAL BASKI İNDEKSİ.

N	Başarı [%95 GA]	Çarp.	Z.aşımı	Nav (s)	$I_{sp}(\times 10^{-3})$
5	97.2 [94.3, 98.6]	2.8	0.0	10.25	10.8
10	89.6 [85.2, 92.8]	10.4	0.0	11.20	10.0
15	85.6 [80.7, 89.4]	14.4	0.0	11.81	8.2
20	79.2 [73.7, 83.8]	20.8	0.0	12.68	7.5

D. Niteliksel: gerçek yörüngeler

Şekil 5, şampiyonun (v30) kalabalık içinde ürettiği gerçek yörüngeleri gösterir. Robot, düz-çizgi (beeline) yerine kalabalığın arasından kavisli bir güzergâh izler; yoğunluk arttıkça (N=10→20) güzergâh uzar ve karmaşılaşır (45→78 adım). Bu, nav-sürenin yoğunlukla artması beklentisiyle tutarlıdır — yani gerçek bir sosyal kaçınma, kalabalığın yol açmasıyla oluşan bir beeline değil.

E. Açığı kapatmaya çalışan altı kaldıraç

Benimsenen yapılandırmanın (v30) üzerine, kalan yüksek-N açığı hedefleyen altı tek-değişkenli model kaldırıcı denir. Beşi v30'u yüksek yoğunlukta geçemez; altıncısı (v34, Beta) tek yön-doğru kaldıraçtır ancak tek-tohumda Bonferroni eşiğini aşamaz (Tablo VI, Şekil 6):

- **Ek kapasite** iki biçimde başarısız: daha büyük NCP düğümü (v31) ve kanonik 4-başlı dikkat (v33) yüksek-N'i kötüleştirir (v33 N=15 -9.6 pp, $p = 0.006$, Bonferroni-anlamlı). v30, bu bütçe/tohum için bir kapasite tatlı-noktasıdır.
- **Müfredat erişimi + bütçe** (v32; $N \rightarrow 25$, 4 M adım) düz kalır: en güçlü etki in-distribution N=10'dadır, hedeflenen N=20 ise düzdür (-0.4 pp).
- **Beta eylem dağılımı** (v34) altı kaldıraç içinde tek yön-doğru olamıdır: v30'u N=10/15/20'de hem başarı hem

çarpışmada nokta-tahminle domine eder (N=20 başarı $+6.8$ pp, $p = 0.045$; çarpışma -7.6 pp, $p = 0.024$) ve tüm sweep'in en iyi yüksek-N değerlerini verir (N=15/20 başarı %91.2/%86.0). Ancak hiçbir yoğunlukta Bonferroni eşiğini ($\alpha=0.0125$) aşamaz — gözlenen nokta etki yön-doğru, ancak tek eğitim-tohumu altında istatistiksel olarak kesinleşmez (Cohen $h \approx 0.18$). Saf tek-değişken değildir: Beta, Gauss'tan farklı entropi ölçeği nedeniyle ayarlı bir entropi katsayısıyla ($c_2=0.001$) birlikte uygulanır; ayrıca 1000 bölümde 3 zaman aşımı görülür.


- **Dikkat sayı-ölçeklemesi** (v29, Eq 13 $n/\sqrt{d_k}$): tek somut kalan paper-sadakat kaldırıcı. v28 tabanı üzerine denendi (başarı 87.6/89.2/86.4/78.8) ve yüksek-N'i anlamlı iyileştirmede — bu nedenle v30, bunun yerine mean+max havuzlamasını temel aldı.
- **Algı-menzili maskesi** (v35) — bir sonraki alt-bölümün konusu.

F. Algı bütçesine inmek açığı genişletir

Makale, robotun algısını challenging arenada 6 m ile sınırlar; bizim uygulamamız ise (v30 dahil) tüm yayaları gözlemler. Bu, hem bir sadakat uyumsuzluğu hem de bir “washout” adayıdır: belki uzak yayalar dikkat ortalamasını seyreltmektedir. v35, bu hipotezi sınar — politika içinde 6 m ötesindeki yayaları maskeler (eğitim ve değerlendirme bu maskeyle yapılır), başka hiçbir şey değişmez.

Sonuç, washout hipotezini doğrulamaz; aksine maske yüksek yoğunlukta geriye işler (Şekil 7): N=15 %85.6→%79.2, N=20 %79.2→%69.6 ($z = -2.46$, $h = -0.22$; fark %95 GA $[-17.2, -2.0]$ sıfırı dışlar, ancak $p = 0.0139$ Bonferroni eşiği 0.0125'i kıl payı aşamaz). Kaybedilen her başarı bir çarpışmaya dönüşür (N=20 çarpışma %20.8→%30.4). Yorum: 6 m ötesini gizlemek gürültüyü değil, robotun uzaktan yaklaşan tehdidi erken görüp kaçınmak için kullandığı sinyali siler; N büyüdükçe daha çok yaya 6 m dışında kaldığından zarar artar. Bir uyarı: maske havuzlama aşamasındadır — uzaysal

Şampiyon (v30) kalabalıkta gerçek yörüngeler — paper_challenging



Şekil 5. Şampiyon (v30) gerçek yörüngeleri (paper_challenging, robot 1.0 m/s). Mavi: robot yörüngesi; gri: yayalar (yol + son konum); kırmızı yıldız: hedef. Gösterilenler *temsili başarılı* epizotlardır (her yoğunlukta sabit bir seçim kuralıyla bulunan ilk başarılı epizot). Robot her iki yoğunlukta da kavisli kaçınma yapar; N=20’de güzergâh belirgin biçimde uzar (gerçek kaçınma, beeline değil).

Tablo VI

ALTI KALDIRAÇ: DÜRÜST ÇOK-TOHUMLU BAŞARI / ÇARPISMA (%) VS BENİMSENE V30 (250 BÖLÜM/YOĞUNLUK). KALIN = v30; *italik* = v34 (TEK YÖN-DOĞRU KALDIRAÇ: NOKTA-TAHMINLE DOMINE EDER AMA BONFERRONI-ALTI). BEŞİ YÜKSEK-N’DE V30’U GEÇEMEZ. V29 (COUNT-ÖLÇEKLEME) V28 TABANLI OLDUĞUNDAN AYRI TUTULUR (METİN).

N	v30 (şampiyon)	v31 node-kap.	v32 $N \rightarrow 25+4M$	v33 4-baş MHA	v34 Beta	v35 sense-6m
5	97.2 / 2.8	92.8 / 7.2	97.6 / 2.8	95.6 / 4.8	96.8 / 2.8	96.8 / 2.8
10	89.6 / 10.4	84.0 / 16.0	94.0 / 6.0	84.4 / 15.6	92.8 / 7.2	89.6 / 10.0
15	85.6 / 14.4	78.8 / 21.2	87.6 / 13.2	76.0 / 24.0	<i>91.2 / 8.8</i>	79.2 / 20.8
20	79.2 / 20.8	72.8 / 27.6	78.8 / 21.2	70.8 / 29.2	<i>86.0 / 13.2</i>	69.6 / 30.4

LTC kodlayıcı tüm yayaları görmeye devam eder; dolayısıyla bu, tam bir kısmî-gözlem (POMDP) kısıtı değil, dikkat/havuz seviyesinde bir bilgi kısıtıdır.

Asıl çıkarım, açık sorusunu doğrudan yanıtlar. Makale %94’ü *yalnızca* 6 m algıyla alır; bizim v30 (tüm yayalar) N=15/20’de %85.6/%79.2, v35 (6 m havuz-maskesi, makalenin algı kısıtına yaklaşım) ise %79.2/%69.6 alır. Yani makalenin algı bütçesine inmek açığı kapatmaz, *genişletir*. Açık “robot ne kadar görüyor” değil, “gördüğüyle ne yapıyor” (temsil/kodlama kalitesi) sorunudur.

G. Standard senaryo: ikinci, bütçe-kaynaklı açık


Şampiyonu makalenin *standard* senaryosunda da (5 yaya, 10×10 arena, 12.5 s bütçe) aynı dürüst protokolle değerlendirdik. v30 burada **%85.6 başarı / %3.6 çarpışma / %10.8 zaman aşımı** (250 bölüm) alır; makale %99.5 bildirir (Tablo I). Önemli nokta: challenging’de açık *çarpışma* kaynaklıyken (zaman aşımı %0), standard’da açık büyük ölçüde *zaman aşımı* kaynaklıdır — robot, dar 12.5 s bütçesi altında bazı bölümleri zamanında tamamlayamaz. Bu, iki ayrı arıza kipini

ortaya koyar ve şampiyonumuzun (esas olarak challenging holdout’unda seçilmiş) standard senaryonun sıkı bütçesine tam genelleşmediğini gösterir. Standard açığı, eğitim/seçim ölçütünün her iki senaryo bütçesini de eşit ağırlıklamasıyla (ör. standard-ağırlıklı holdout veya senaryoya-özel ince-ayar) hedeflenmelidir.


VI. TARTIŞMA

Sonuçlar tutarlı bir resim çizer. Açığı kapatan değişiklikler *temsili sadakati ve eğitim dağılımı* ile ilgilidir: ön-MLP, ham sinyali NCP’ye vermeden önce zenginleştirir; mean+max, küme özetini kardinaliteye dayanıklı kılar; müfredat, test yoğunluklarını eğitim dağılımına dahil eder. Açığı kapatmayan değişiklikler ise *ham kapasite, alternatif dikkat/dağılım veya algı kısıtı* ile ilgilidir. İki kapasite-ekleme (v31, v33) ve perception kısıtı (v35) yüksek-N’i bozar; bu, v30’un sabit bütçe/tohum altında bir denge noktası olduğunu ve kalan açığın temsil-kullanımında yattığını gösterir.

Kalan açık iki ayrı eksene ayrışır. *Challenging* senaryoda açık *çarpışma* kaynaklıdır (zaman aşımı %0) ve yukarı-



Şekil 6. Beş v30-tabanlı kaldırıcın yüksek-N farkı (altıncı, v29, v28-tabanlı olduğundan metinde). Sol: başarı farkı (pp); sağ: çarpışma farkı (pp). Yalnızca v34 (Beta, yeşil vurgu) doğru yöndedir (başarı +, çarpışma -) ama Bonferroni-altıdır; diğer dördü yüksek yoğunlukta v30'u kötüleştirir.



Şekil 7. Algı-menzili ablasyonu (v35). v30 (tüm yayalar) ile v35 (6 m havuz-maskesi $\approx$ makalenin algı kısıtı) ve makale (yeşil) karşılaştırması. 6 m bütçeye inmek başarıyı yüksek-N'de düşürür (sol) ve çarpışmayı artırır (sağ): algı menzili açığın nedeni değildir.

daki temsil-kullanımı tartışmasına aittir. *Standard* senaryoda ise açık zaman aşımı kaynaklıdır (%10.8): challenging holdout'unda seçilen şampiyon, standard'ın dar 12.5 s bütçesine fazla temkinli davranır. İki arıza kipinin farklı olması, tek bir "açık" yerine iki ayrı müdahale gerektiğini ima eder: challenging için daha iyi temsil, standard için bütçe-duyarlı seçim/ince-ayar.

Bu, gelecek çalışma için somut bir yön verir: kalan ~ 9 pp'lik yüksek-N (challenging) açığı, daha fazla algı veya parametre ile değil, kodlayıcının aynı yerel bilgiden daha iyi yararlanmasıyla (ör. daha güçlü zamansal modelleme, daha iyi kalibre edilmiş eğitim sinyali) hedeflenmelidir; standard açığı ise senaryoya-özel bütçe duyarlılığıyla.

VII. SINIRLAMALAR

Tek eğitim-tohumu. Tüm sürümler tek bir eğitim tohumuyla eğitildi; değerlendirme çok-tohumlu olsa da eğitim varyansı tahmin edilmedi ($\pm$ birkaç puanlık gölge mümkün). Çoklu eğitim-tohumu en öncelikli sağlamlaştırmadır. **Değerlendirme ölçeği.** Yoğunluk başına 50 (havuzda 250) bölüm kullandık; makale 500 kullanır. **İki-değişken (v32).** Müfredat erişimi ve bütçe birlikte değiştiği için atıf muğlaktır. **Beta**

ablasyonu (v34). Beta, Gauss'tan farklı entropi ölçeği nedeniyle ayarlı bir entropi katsayısıyla ($c_2=0.001$) birlikte eğitildi; dolayısıyla saf tek-değişken değildir (kazanç yalnız Beta'ya atfedilemez). Yön-doğru sonucu (N=10/15/20'de nokta-tahminle üstün) tek-tohumda Bonferroni-altı kalır; çoklu eğitim-tohumu veya per-episode kaydedilmiş eşleştirilmiş bir test bunu doğrulayabilir. **Senaryo-genellemesi.** Şampiyon esas olarak challenging holdout'unda seçtiğinden standard senaryoda zaman aşımı kaynaklı geriler (%85.6); tek bir checkpoint'in her iki paper senaryosunda da yüksek olması (makaledeki gibi) ayrı bir hedef olarak ele alınmadı. **Doğrulanamayan makale ayrıntıları.** ORCA parametreleri ve bazı eylem sınırları makalede verilmediğinden reproduksiyon açığının bir kısmı kaçınılmazdır.

VIII. SONUÇ

SNCP-PPO'yu makalenin değerlendirme rejiminde sadık biçimde yeniden kurduk ve "%94'e neden ulaşamıyoruz" sorusunu ölçülebilir bileşenlere ayırtırdık. İki sadakat düzeltmesi ve mean+max katkımız açığın yarından çoğunu kapatır (N=10 %61.6 $\rightarrow$ %89.6); buna karşın denenen altı model kaldırıcından beşi (ek kapasite, çok-başlı dikkat, algı-menzili maskesi vb.) şampiyonu yüksek yoğunlukta geçemez; yalnızca Beta eylem dağılımı yön-doğru (N=10/15/20'de nokta-tahminle üstün, N=5'te eşdeğer) ama tek-tohumda Bonferroni-altı bir iyileşme verir. Özellikle, robotun algısını makalenin kendi 6 m bütçesine indirmek açığı genişletir — bu, kalan açığın algı menziline değil, temsil kullanımından kaynaklandığını gösterir. Kalan açığın iki ayrı eksene ayrıştığını da gösterdik: challenging'de *çarpışma* (temsil-kullanımı), standard'da *zaman aşımı* (bütçe duyarlılığı). Bir metodolojik katkı olarak, best-holdout ölçütünün seçim-saplı olduğunu gösterdik ve tüm kıyasları çok-tohumlu, istatistiksel olarak denetlenmiş bir protokole bağladık.

KAYNAKLAR

- [1] T. Ao, H. Li, Y. Tian *et al.*, “Human-centric motion planning in crowded spaces: A structured neural circuit approach with social interaction-awareness,” *International Journal of Social Robotics*, vol. 18, 2026, makale no. 52.
- [2] R. Hasani, M. Lechner, A. Amini, D. Rus, and R. Grosu, “Liquid time-constant networks,” in *Proceedings of the AAAI Conference on Artificial Intelligence*, vol. 35, 2021, pp. 7657–7666.
- [3] M. Lechner, R. Hasani, A. Amini, T. A. Henzinger, D. Rus, and R. Grosu, “Neural circuit policies enabling auditable autonomy,” *Nature Machine Intelligence*, vol. 2, no. 10, pp. 642–652, 2020.
- [4] J. Schulman, F. Wolski, P. Dhariwal, A. Radford, and O. Klimov, “Proximal policy optimization algorithms,” *arXiv preprint arXiv:1707.06347*, 2017.
- [5] J. van den Berg, S. J. Guy, M. Lin, and D. Manocha, “Reciprocal n-body collision avoidance,” in *Robotics Research: The 14th International Symposium ISRR*, ser. Springer Tracts in Advanced Robotics. Springer, 2011, vol. 70, pp. 3–19.
- [6] C. Chen, Y. Liu, S. Kreiss, and A. Alahi, “Crowd-robot interaction: Crowd-aware robot navigation with attention-based deep reinforcement learning,” in *IEEE International Conference on Robotics and Automation (ICRA)*, 2019, pp. 6015–6022.
- [7] A. Vaswani, N. Shazeer, N. Parmar, J. Uszkoreit, L. Jones, A. N. Gomez, L. Kaiser, and I. Polosukhin, “Attention is all you need,” in *Advances in Neural Information Processing Systems (NeurIPS)*, 2017.
- [8] M. Zaheer, S. Kottur, S. Ravanbakhsh, B. Póczos, R. Salakhutdinov, and A. J. Smola, “Deep sets,” in *Advances in Neural Information Processing Systems (NeurIPS)*, 2017, pp. 3391–3401.
- [9] C. R. Qi, H. Su, K. Mo, and L. J. Guibas, “Pointnet: Deep learning on point sets for 3d classification and segmentation,” in *IEEE Conference on Computer Vision and Pattern Recognition (CVPR)*, 2017.
- [10] P.-W. Chou, D. Maturana, and S. Scherer, “Improving stochastic policy gradients in continuous control with deep reinforcement learning using the beta distribution,” in *Proceedings of the 34th International Conference on Machine Learning (ICML)*, ser. PMLR, vol. 70, 2017.
- [11] P. Henderson, R. Islam, P. Bachman, J. Pineau, D. Precup, and D. Meger, “Deep reinforcement learning that matters,” in *Proceedings of the AAAI Conference on Artificial Intelligence*, vol. 32, 2018.
- [12] R. Agarwal, M. Schwarzer, P. S. Castro, A. C. Courville, and M. G. Bellemare, “Deep reinforcement learning at the edge of the statistical precipice,” in *Advances in Neural Information Processing Systems (NeurIPS)*, vol. 34, 2021.